L'IA pour les sciences et l'ingénierie

L1.UE5 - Initiation à l'Intelligence Artificielle

Simon BERNARD
simon.bernard@univ-rouen.fr

Les succès récents de l'IA

Reconnaissance d'images et de vidéos

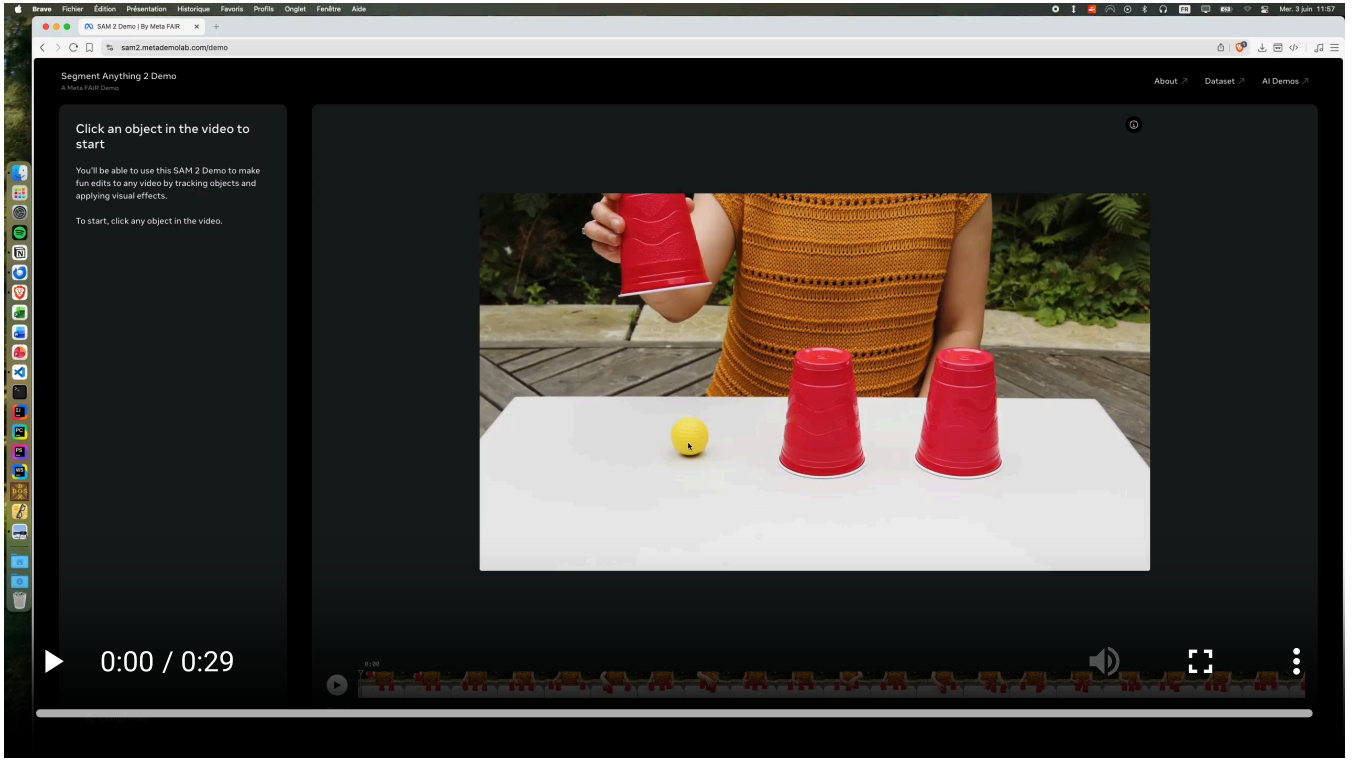

SAM 2, Facebook AI Research (2024)

Les succès récents de l'IA

Génération d'images et de vidéos

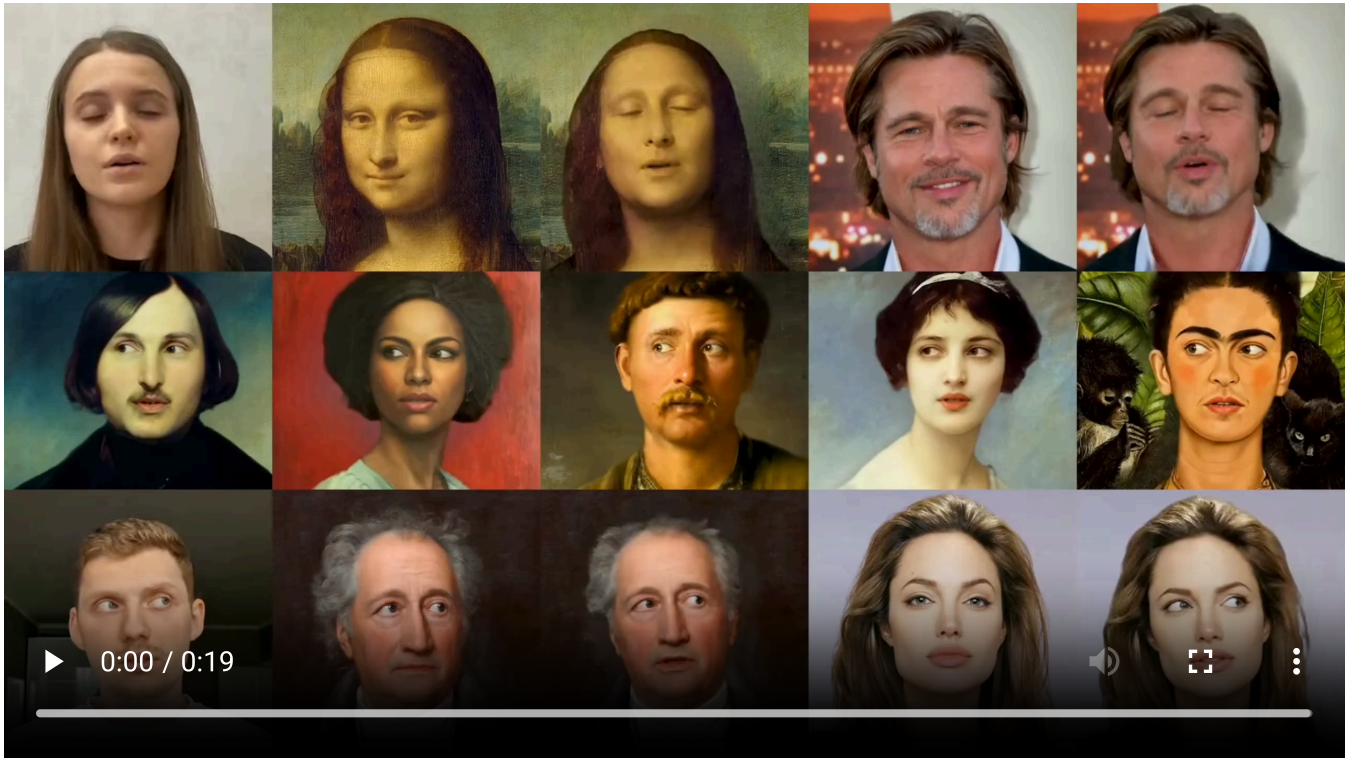

MegaPortraits, Samsung (2022)

Les succès récents de l'IA

Traitement du langage naturel

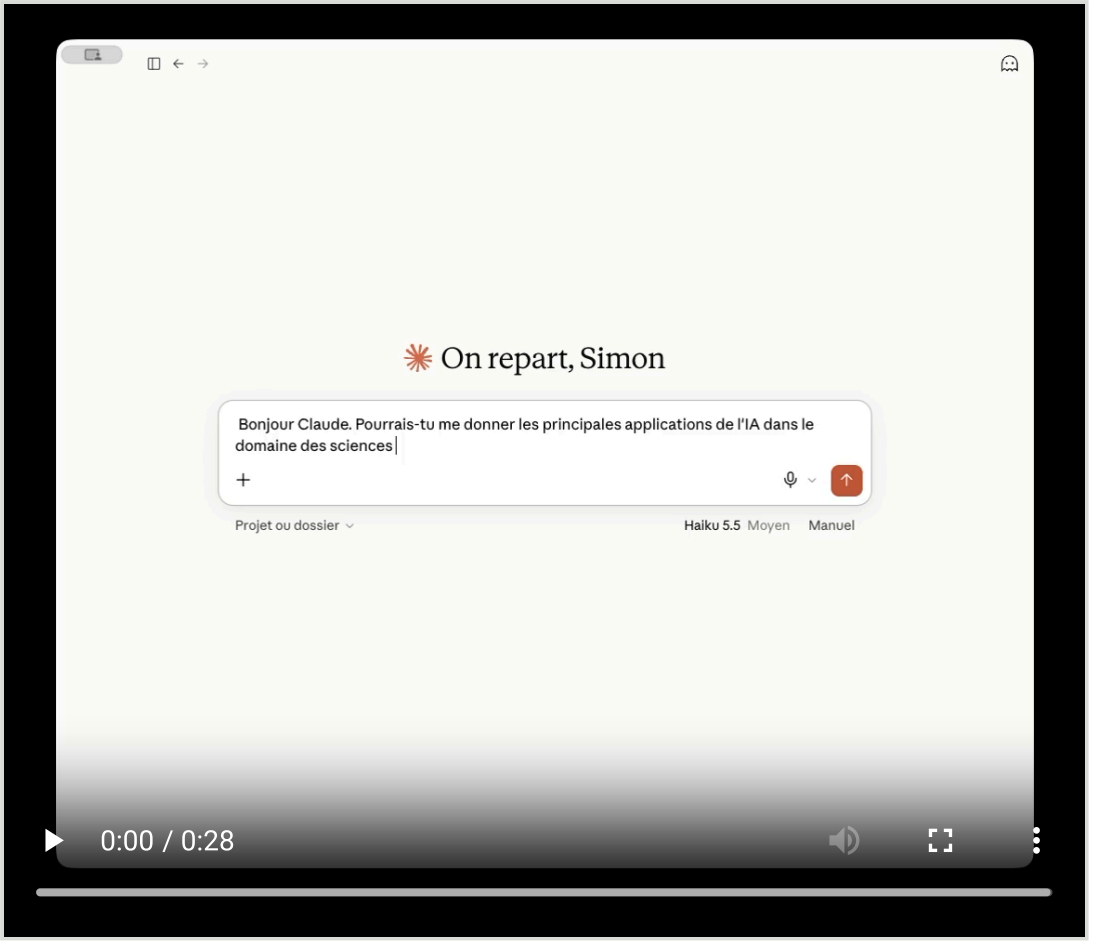

Claude AI, Anthropic

Les succès récents de l'IA

IA autonome

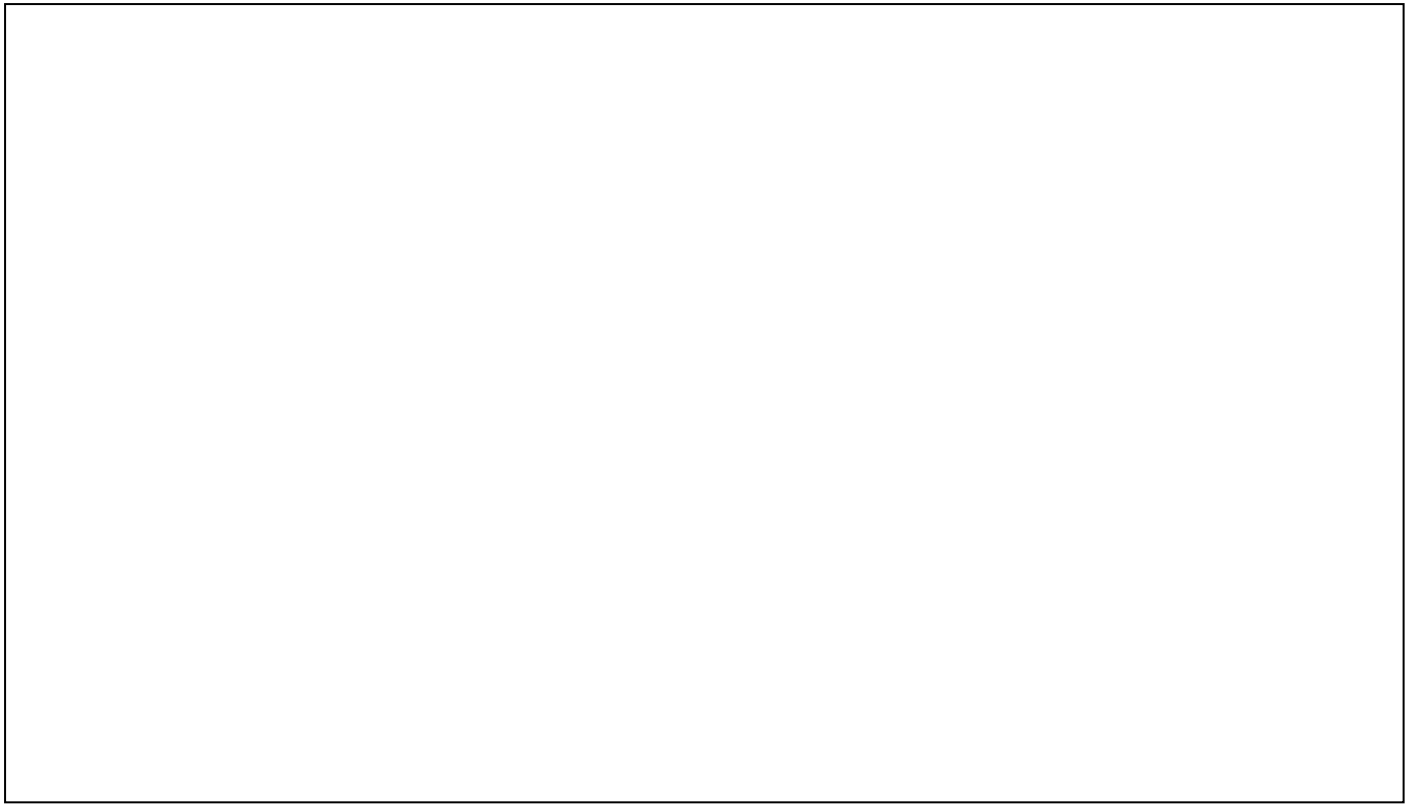

Large Behavior Models, Boston Dynamics & Toyota Research Institute (2025)

Apprentissage automatique

Ces IA sont basées sur l'apprentissage automatique (*machine learning*), qui consiste à apprendre/entrainer des modèles prédictifs à partir de données exemples.

Le pipeline de l'apprentissage automatique est divisé en deux phases:

- **L'apprentissage**: on apprend un modèle à partir des données d'apprentissage
- **L'inférence**: on utilise le modèle pour prédire la sortie de chaque nouvelle donnée

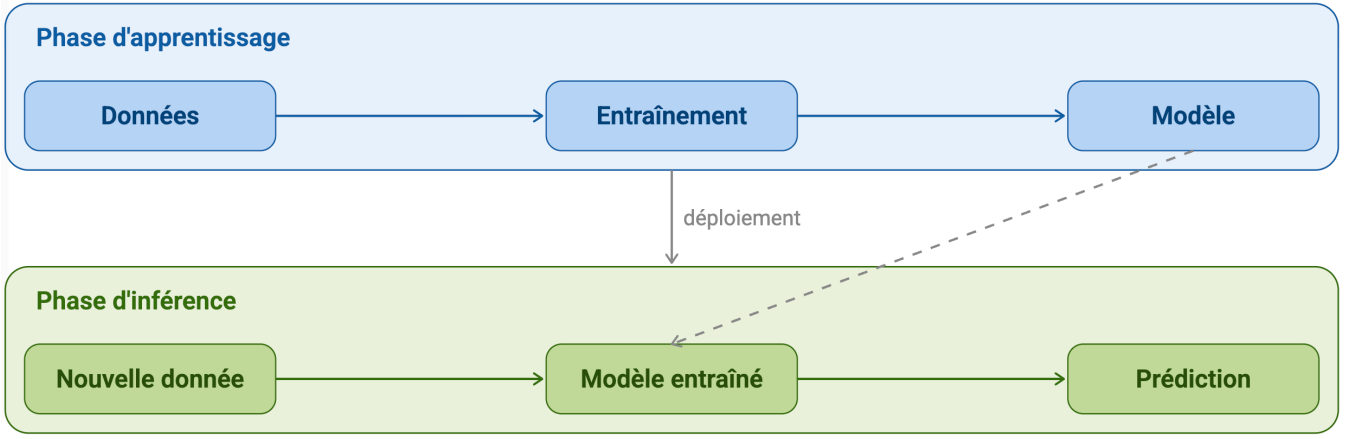

Comment faire l'apprentissage?

70 ans de recherche = une multitude de méthodes issues:

- des statistiques
- de l'optimisation mathématique
- de la théorie de l'informaiton
- du traitement du signal
- de la théorie des jeux
- ...

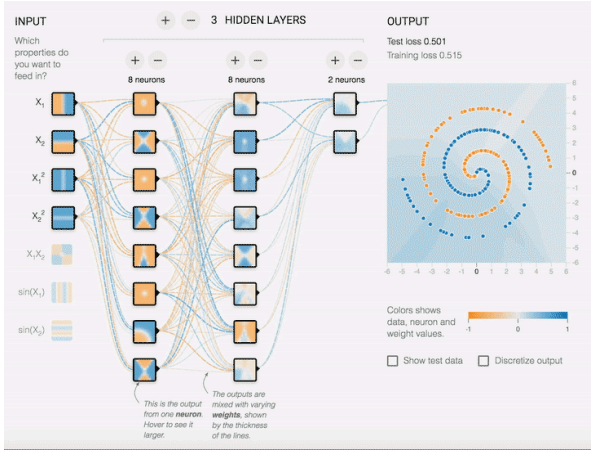

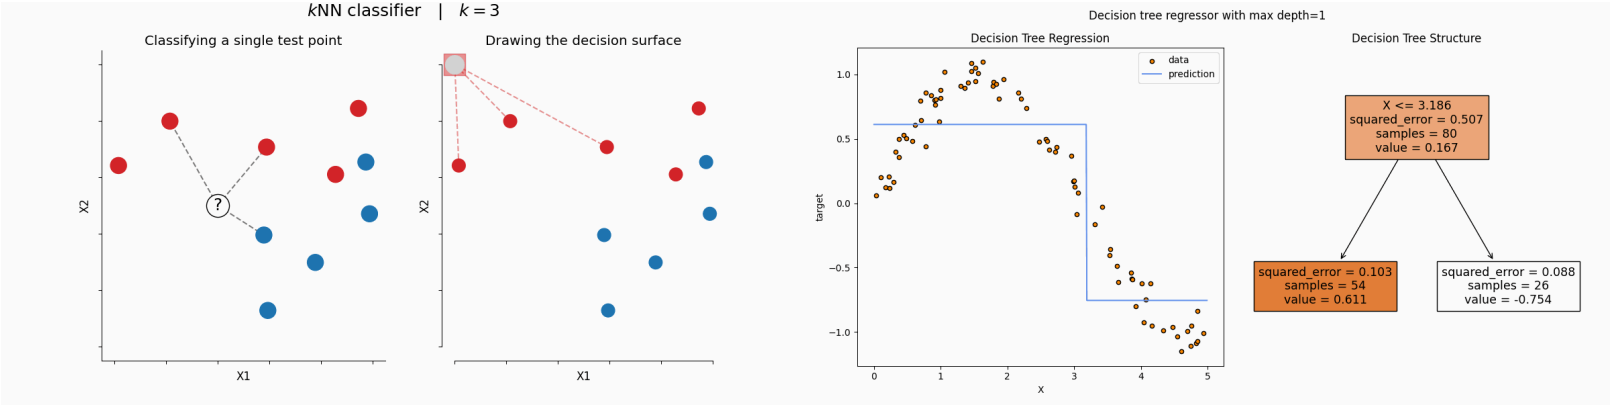

Comment faire l'apprentissage?

Parmi ces méthodes, il y a les réseaux de neurones:

- Dans les années 1950, inspiration du fonctionnement des neurones biologiques
- Réseau de neurones = assemblage de plusieurs neurones (beaucoup!)
- Apprentissage = ajuster les paramètres du réseau pour qu'il produise la bonne sortie pour chaque donnée en entrée

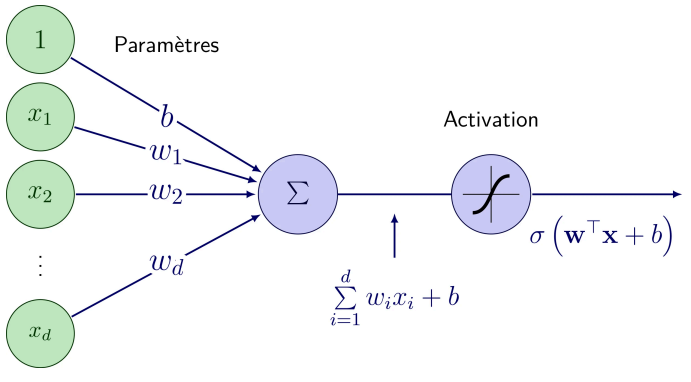

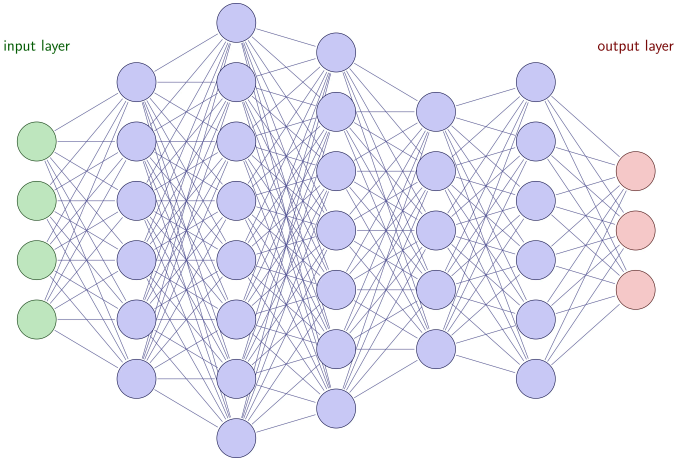

L'IA d'aujourd'hui ≈ Deep Learning

Les **réseaux de neurones profonds** sont à la base des méthodes d'IA modernes

- Plus il y a de neurones...
- ... plus il y a de paramètres à apprendre
- ... plus il faut de données d'apprentissage
- ... plus l'apprentissage est coûteux en temps de calcul et en argent
- ... mais plus le modèle est puissant et peut résoudre des problèmes complexes

Par exemple, GPT-3 (le modèle de ChatGPT à sa sortie en 2020) [1]

- 175 milliards de paramètres
- 350 Go pour stocker le modèle
- 950 Go de textes pour l'apprentissage
- 34 jours de calculs, équivalent à 355 années/GPU (et 4.6 M$)

(1) GPT-4 (2023) est estimé à 10^{12} paramètres et $25,000$ GPUs pour un apprentissage sur 6 mois, mais il s'agit d'estimation car les détails exactes n'ont pas été publiés.

L'IA d'aujourd'hui ≈ Deep Learning

Ces méthodes existent depuis les années 50, alors pourquoi ça ne fonctionne que depuis 2010?

Abondance des données

Dispositifs de calcul puissants (GPU)

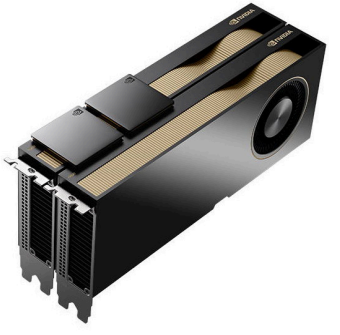

Développement de logiciels dédiés

PyTorch TensorFlow

PyG

mxnet DGL DEEP GRAPH LIBRARY

Apprentissage de représentations

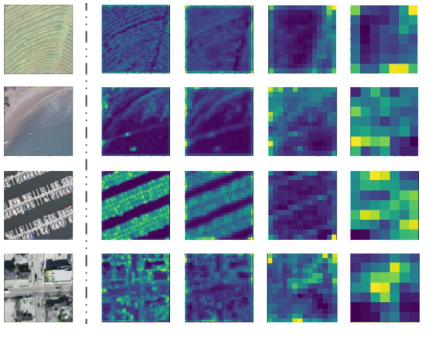

Apprentissage de représentations

Une **représentation** est une manière de décrire une donnée brute (pixels, mots, mesures) par un vecteur de nombres, où l'information utile à la tâche est facilement accessible.

Approche classique

- On conçoit à la main les caractéristiques (*feature engineering*)
- Demande une expertise du domaine
- Difficile sur des données complexes (images, textes, signaux)

Apprentissage de représentations

- Le modèle apprend lui-même les caractéristiques utiles
- Représentation et tâche sont apprises ensemble
- Les couches profondes construisent des représentations de plus en plus abstraites

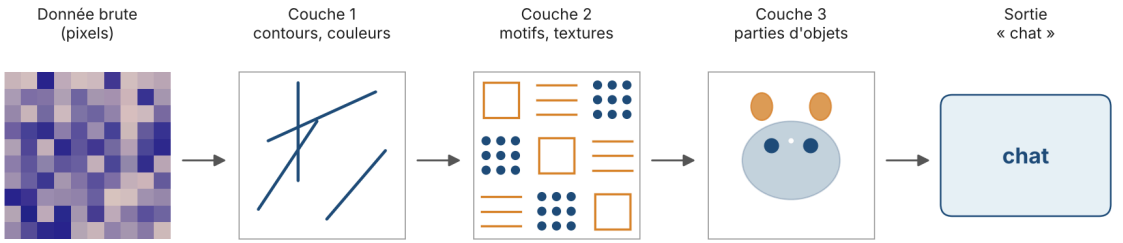

Chaque couche construit ses représentations à partir de la couche précédente.
Les représentations sont apprises à partir des données, sans être conçues à la main.

Apprentissage de représentations

Illustration

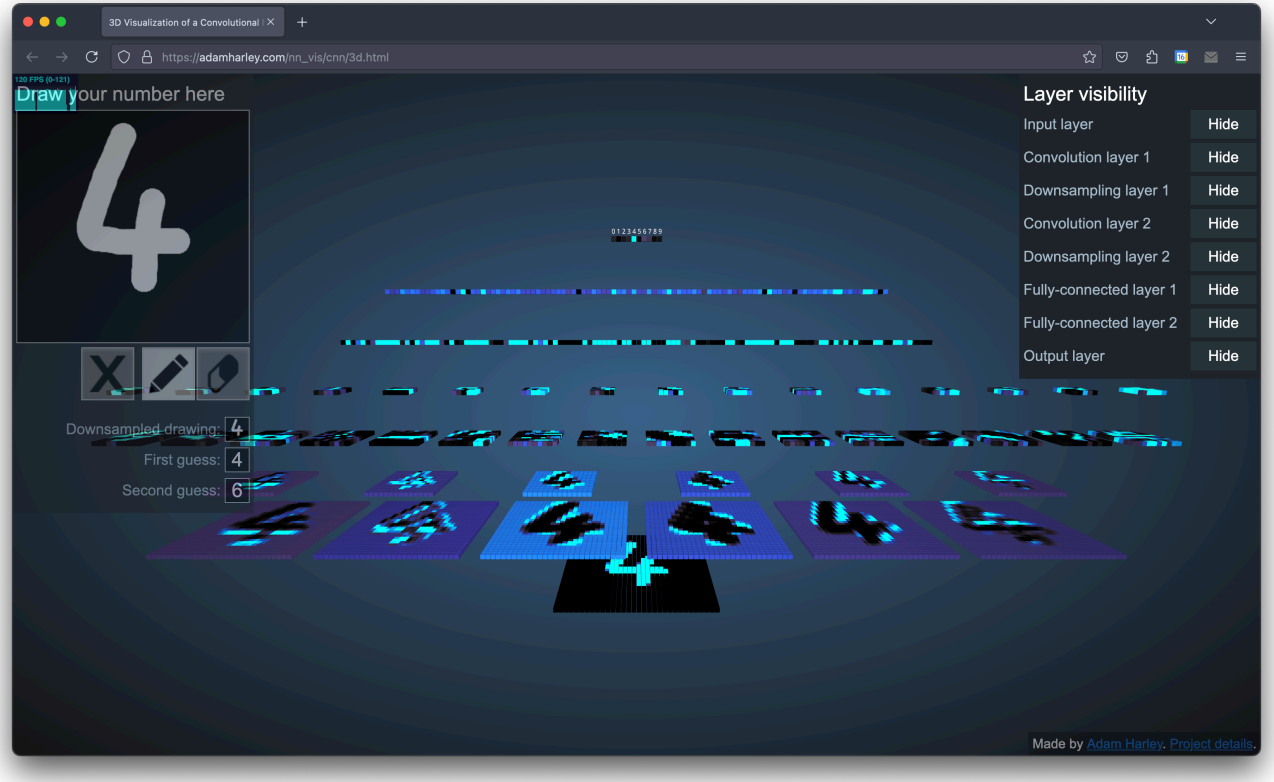

https://adamharley.com/nn_vis/

L'IA pour les sciences

L'IA en science et en ingénierie

Applications numériques

- Données abondantes et bon marché (clics, images, textes)
- Pas de besoin d'interprétabilité : le modèle est une "boîte noire"
- Erreurs tolérées : peu d'impact si elles sont très minoritaires
- Besoin en généralisation limité : les données d'entraînement sont représentatives des données futures

Science et ingénierie

- **Données rares et coûteuses** : une expérience ou une simulation peut durer des jours
- Une bonne prédiction ne suffit pas : il faut une **validation physique ou expérimentale**
- Erreurs à fort coût : sécurité, décision, publication
- Le modèle doit **généraliser hors de ses données d'entraînement** : on lui demande d'extrapoler vers des conditions nouvelles

L'IA ne doit pas juste être performante, elle doit être cohérente avec les lois scientifiques déjà connues.

Les tâches sont les mêmes, les objets changent

Objet	Exemple	Ce qui le rend difficile	Méthode adaptée
Tableau de mesures	Propriétés d'un matériau	Peu de données, bruit	Modèles classiques (régression, arbres, processus gaussiens)
Image instrumentale	Microscopie, astronomie	Très grandes images, peu d'annotations	Réseaux convolutifs
Séquence temporelle	Capteurs, climat	Dynamique physique, non-stationnarité	Réseaux récurrents, transformers
Graphe	Molécules, réseaux	Structure relationnelle	Réseaux sur graphes
Champ	Fluide, température	Sortie de dimension infinie, lois physiques	Apprentissage d'opérateurs, réseaux informés par la physique

Équations aux dérivées partielles (EDP)

- En science, la grandeur recherchée dépend souvent de l'espace et du temps (e.g. température d'une pièce) → on parle de **champ** $u(x,t)$
- Ces champs sont en général régis par des **équations aux dérivées partielles** (EDP)
- Dérivée partielle de $u(x_1,\dots,x_n):\mathbb{R}^n\to\mathbb{R}$:

$$\frac{\partial u}{\partial x_i}=\lim_{\Delta x_i\to 0}\frac{u(x_1,\dots,x_i+\Delta x_i,\dots,x_n)-u(x_1,\dots,x_i,\dots,x_n)}{\Delta x_i}$$

  i.e. l'amplitude de la variation de u selon la direction x_i
- Équations aux dérivées partielles (EDP):

$$F\left(x_1,\dots,x_n,u,\frac{\partial u}{\partial x_1},\dots,\frac{\partial u}{\partial x_n},\frac{\partial^2 u}{\partial x_1^2},\frac{\partial^2 u}{\partial x_1\partial x_2},\dots\right)=0$$

Équations aux dérivées partielles (EDP)

- Comprendre et résoudre ces équations est crucial pour de nombreuses applications scientifiques et industrielles : simulation aérodynamique, prévision météorologique, modélisation biologique, etc.
- **Les solveurs numériques sont coûteux en temps, intensifs en calcul et parfois complexes**

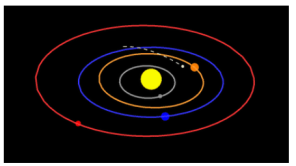

Solar system

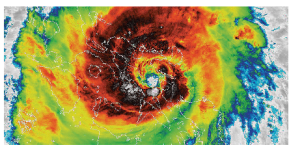

Atmosphere

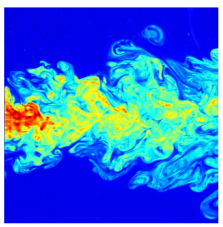

Fluid

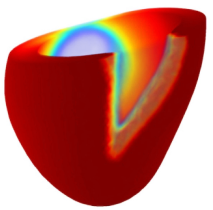

Heart electrical activities

Chemical reactions

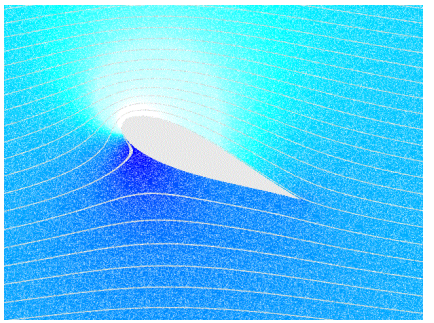

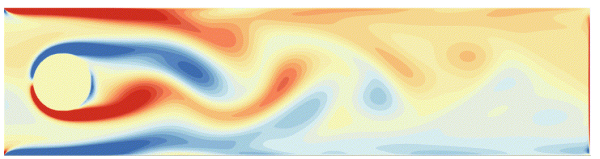

Yuan YIN, soutenance de thèse, Sorbonne Université, 2023

- **Question** : peut-on apprendre à résoudre une EDP à partir de données, ou de la physique seule ?

Pourquoi c'est difficile ?

- Pour entrainer un réseau de neurones à résoudre une EDP, **il faut beaucoup de données**
- Quelle données? des simulations numériques, des mesures expérimentales, des observations réelles
- Obtenir ces données est très coûteux en temps et en ressources, parfois même impossible

Exemple en mécanique des fluides numérique (Naiver-Stokes)

- Besoin de simulations précises et longues
- Plusieurs jours de calculs par simulation
- Besoin de milliers de simulations pour couvrir tous les cas possibles

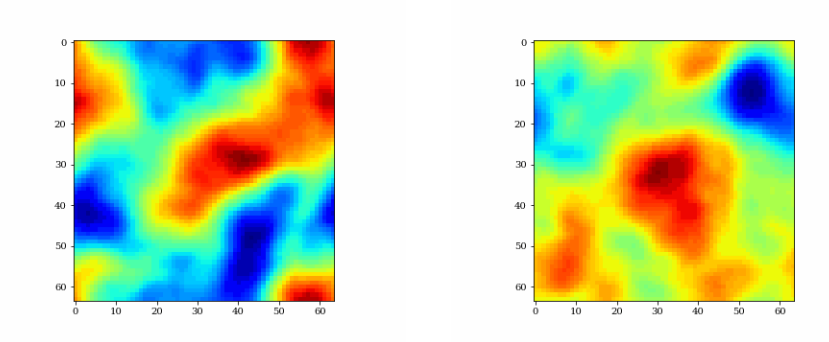

Gauche: exemple d'une simulation numérique courte et de faible qualité;
Droite: simulation obtenue par un réseau de neurones entrainé sur ce type de simulations

Comment faire ?

Scientific Machine Learning (SciML) = combiner les méthodes d'apprentissage automatique avec la physique et les mathématiques

Plusieurs approches:

- **Physics-Informed Neural Networks (PINN)**: apprendre la solution d'une EDP en s'appuyant sur l'équation
- **Neural Operator**: apprendre l'opérateur qui associe au paramètres de l'EDP sa solution complète
- **Hybrid Physics-ML**: combiner un modèle physique avec un modèle appris pour corriger ou accélérer

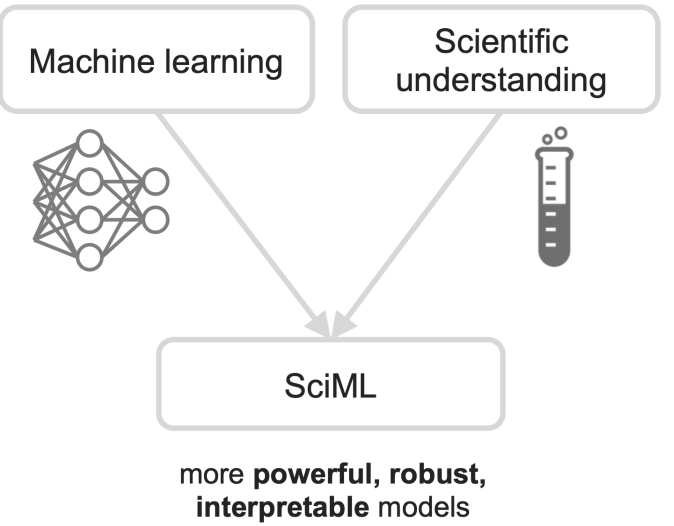

Physics-Informed Neural Network (PINN) [1]

- Réseau de neurones entrainé pour approximer $u_\theta(x,t)$ directement
- Apprentissage pour optimiser la fidélité aux données et la fidélité à l'EDP
- Les dérivées de u_θ s'obtiennent par **différentiation automatique**

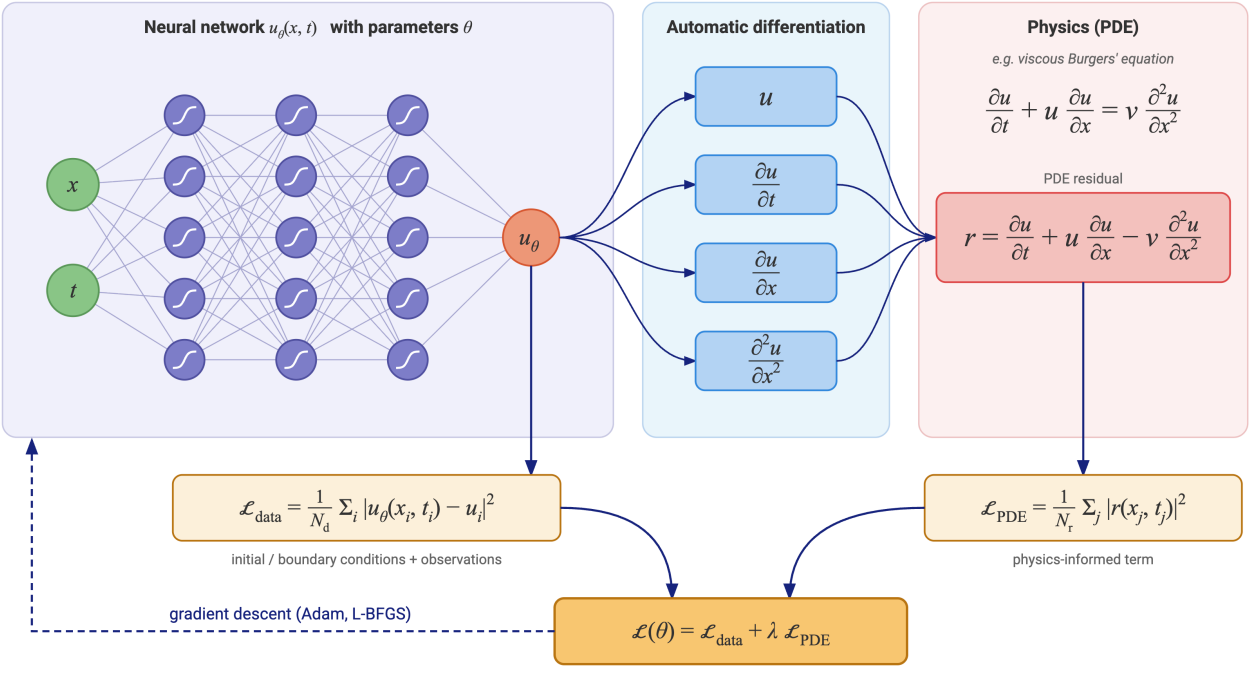

(1) Maziar Raissi, Paris Perdikaris, George Em Karniadakis, "Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations", Journal of Computational Physics, 2019

Example: équation de Burgers

Soit $\nu = 0.01/\pi$, $x \in [-1, 1]$, $t \in [0, 1]$ et $u : [-1, 1] \times [0, 1] \to \mathbb{R}$:

$$\begin{cases} \frac{\partial u}{\partial t} + u\frac{\partial u}{\partial x} - \nu\frac{\partial^2 u}{\partial x^2} = 0 \\ u(x, 0) = -\sin(\pi x) \\ u(-1, t) = u(1, t) = 0 \end{cases}$$

Ci-contre: Réseau entrainé sur:

- 100 points tels que $t = 0$, $x = -1$ ou $x = 1$
- $10,000$ points de collocation dans $[-1, 1] \times [0, 1]$

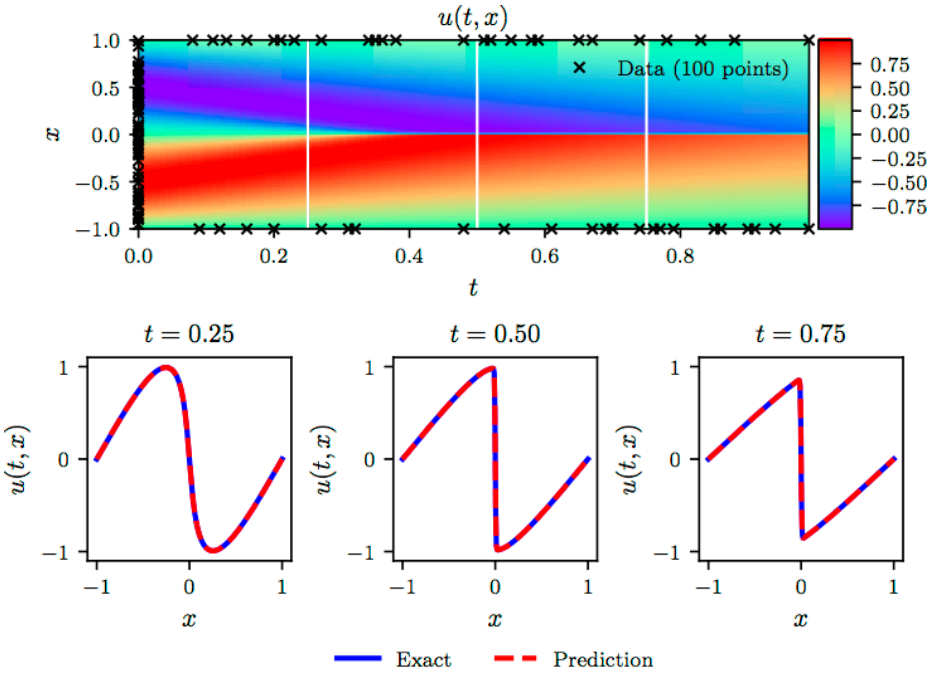

Neural Operator

- Les PINN apprennent la solution d'une EDP avec des conditions initiales et aux limites fixées
- Si on veut résoudre la même EDP avec **d'autres conditions, il faut ré-entrainer le réseau**
- Objectif : apprendre l'**opérateur** $\mathcal{G} : a \mapsto u$, qui associe à une entrée (conditions, paramètres) la solution complète
- A **neural operator** apprend $\mathcal{G}$ à partir d'un ensemble d'instance déjà résolues

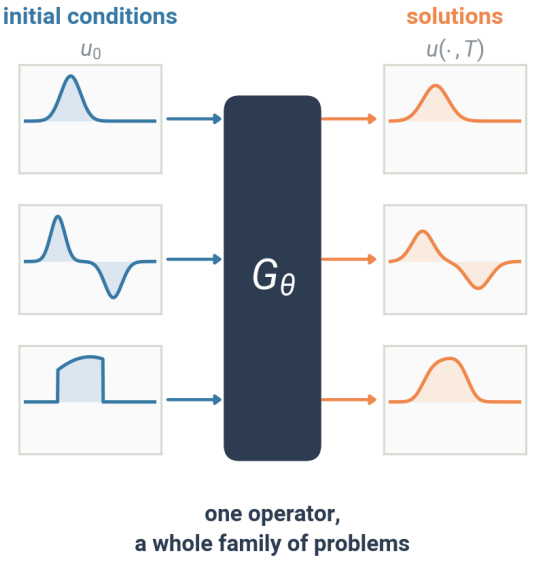

Fourier Neural Operator (FNO) [1]

- Apprend des représentations de a dans l'espace de Fourier (branche du haut): dynamique globale
- Apprend aussi des représentations locales dans l'espace physique (branche du bas): dynamique locale

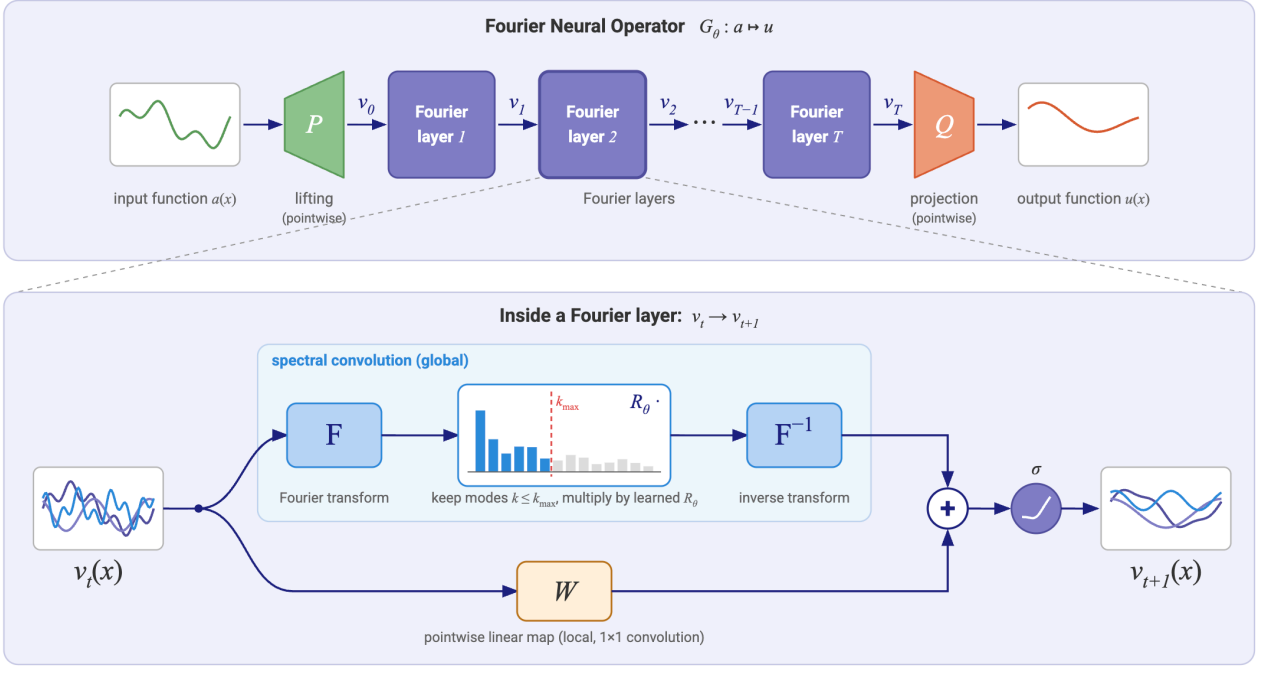

(1) Zongyi Li, Nikola Kovachki, Kamyar Azizzadenesheli, Burigede Liu, Andrew Stuart, Anima Anandkumar, Kaushik Bhattacharya, "Fourier Neural Operator for Parametric Partial Differential Equations", ICLR 2021

Comparaison PINN et FNO

Critère	PINN	FNO
Données nécessaires	Peu, voire aucune	Beaucoup (paires entrée-sortie)
Physique	Imposée dans la fonction de perte	Apprise à partir des données
Nouveaux paramètres	Réentraînement	Évaluation immédiate
Difficulté	Optimisation raide	Coût de génération des données

Ces principes sont encore en développement, mais ils sont déjà utilisés sur des problèmes réels.

AI4Science : Les exemples marquants

Prévisions météorologiques

- **GraphCast** (Google DeepMind, 2023) [1]
- Training data: 40+ years of observations (ECMWF)
- Prediction of weather fields up to 10 days ahead
- 1.2 billion param., 128 TPUv4 chips for training

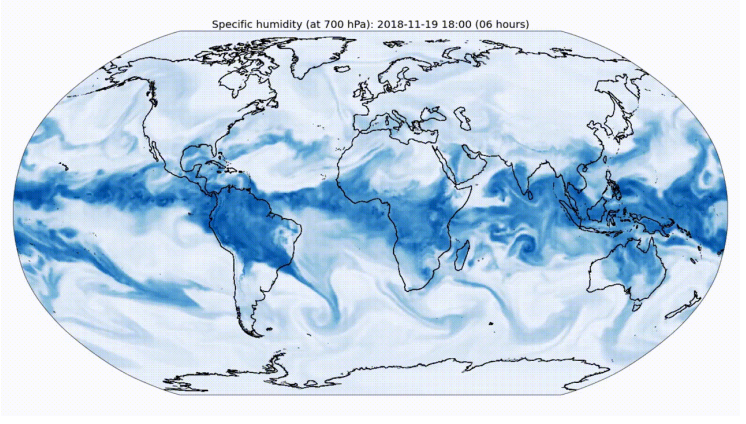

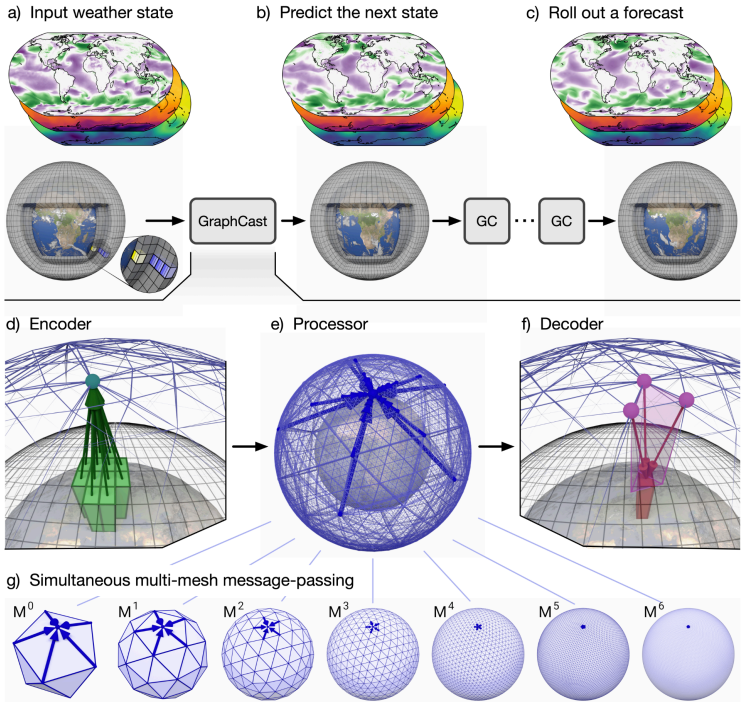

https://deepmind.google/blog/graphcast-ai-model-for-faster-and-more-accurate-global-weather-forecasting/

(1) Renamed with newer versions: GenCast in 2024 and WeatherNext in 2025 (github)

Carte d'activation cardiaque

- Fibrillation auriculaire : le cœur bat trop lentement, trop rapidement ou de manière irrégulière
- Diagnostic avec une carte d'activation électro-anatomiques (activité électrique du coeur)
- Seulement quelques mesures pour produire toute l'activité $\longrightarrow$ interpolation non-trivial
- **PINN pour la génération de carte d'activation cardiaque complète à partir de quelques mesures**

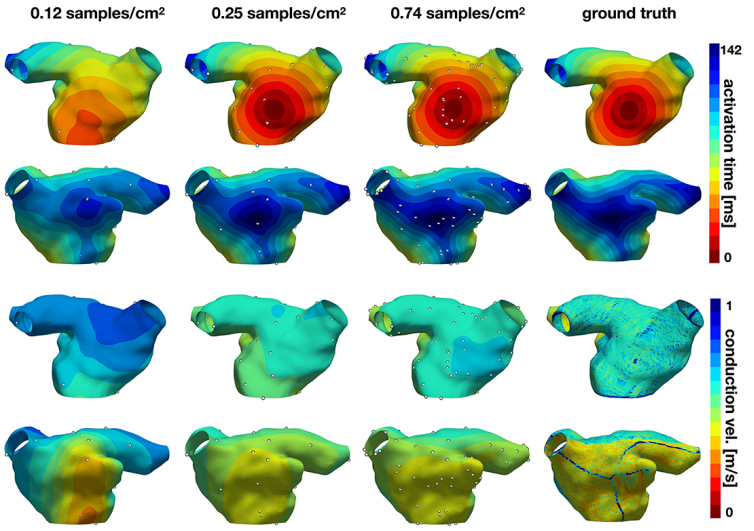

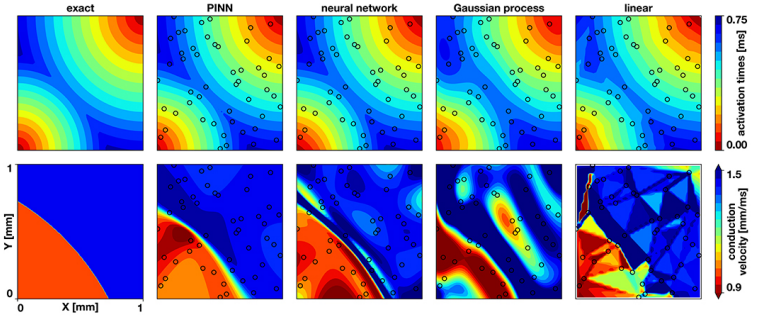

Sahi Costabal et al., "Physics-Informed Neural Networks for Cardiac Activation Mapping", Frontiers in Physics, 2020

Fusion nucléaire

- Fusion nucléaire = fusion de deux atomes pour produire de l'énergie
- Énergie performante, propre et quasi inépuisable (combustible naturel, rendement élevé)
- Expérimental, car très compliqué à maîtriser à cause de l'état instable du plasma utilisé pour la fusion
- **IA pour modéliser et contrôler le plasma dans les réacteurs à fusion**

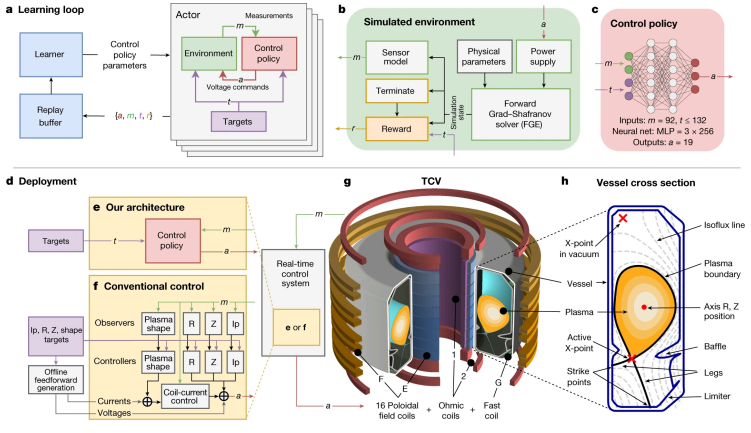

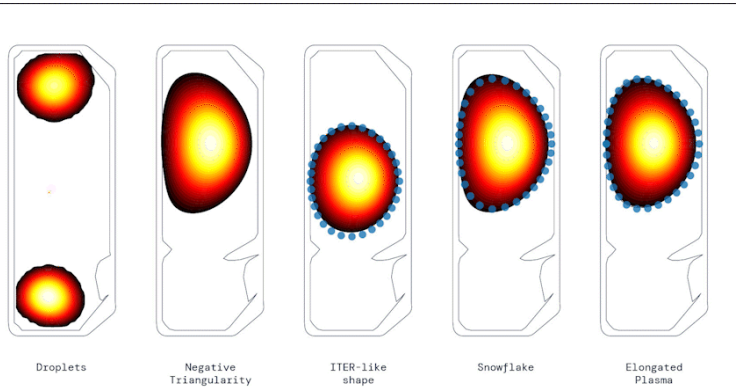

Degrave et al., "Magnetic control of tokamak plasmas through deep reinforcement learning", Nature, 2023

Prédiction de la structure des protéines

- Les cellules vivantes sont constituées de protéines, qui participent aux fonctions essentielles de la vie
- Une protéine est une chaîne d'acides aminés, déterminée par le code génétique (ADN)
- Cette chaîne se replie en une structure 3D spécifique, à la faveur des intéractions chimiques
- **Comprendre, prédire et maîtriser ce repliement est un enjeu majeur en biologie et en médecine**

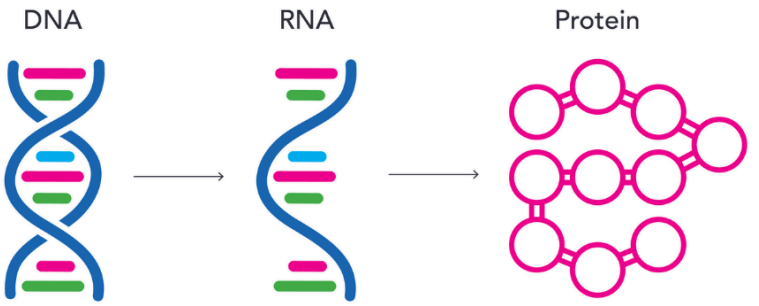

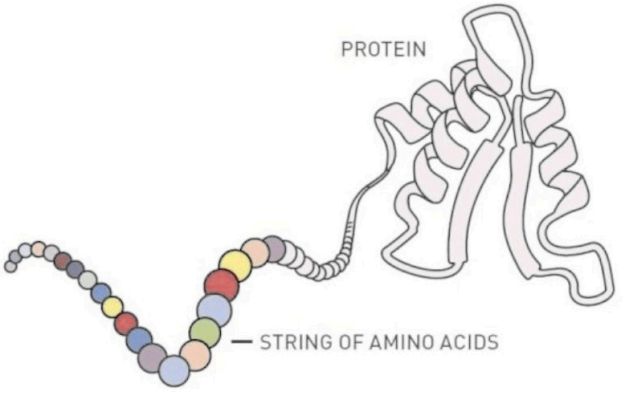

Prédiction de la structure des protéines

- **AlphaFold 2 de Google DeepMind (2021)**
- Entraîné sur 200k+ structures déjà connues
- Prédictions pour presque toutes les protéines connues (~ 200M)
- **Principes d'IA inspirés des LLM et avec une génération itérative**

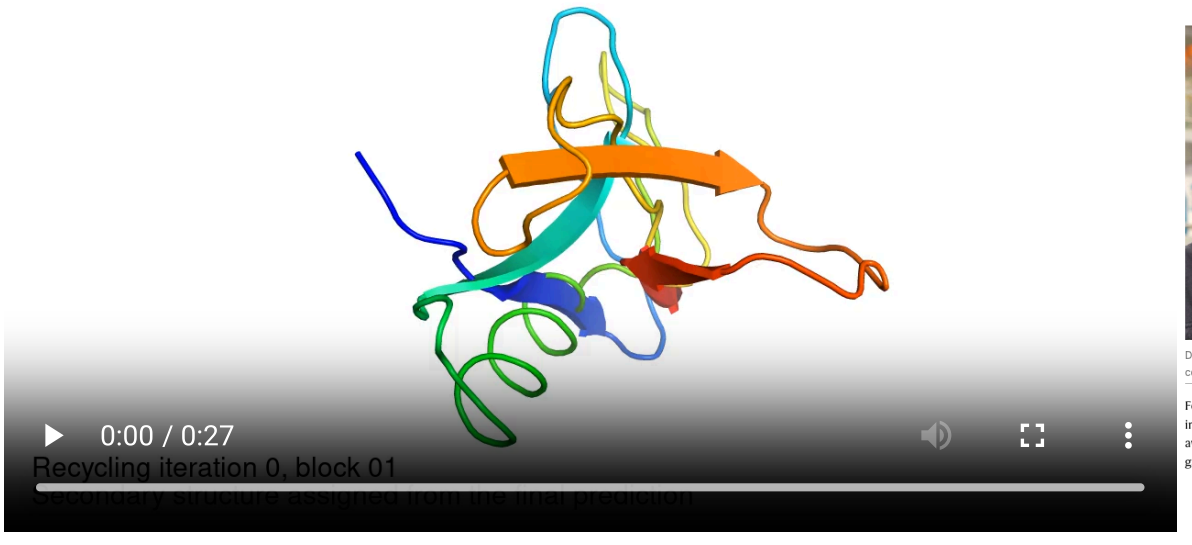

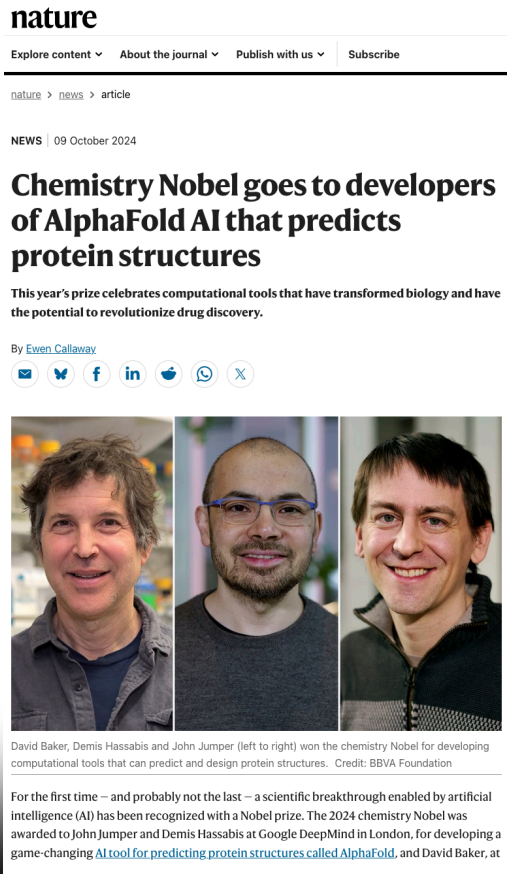

nature

Explore content · About the journal · Publish with us · Subscribe

nature › news › article

NEWS | 09 October 2024

Chemistry Nobel goes to developers of AlphaFold AI that predicts protein structures

This year's prize celebrates computational tools that have transformed biology and have the potential to revolutionize drug discovery.

By Ewen Callaway

David Baker, Demis Hassabis and John Jumper (left to right) won the chemistry Nobel for developing computational tools that can predict and design protein structures. Credit: BBVA Foundation

For the first time – and probably not the last – a scientific breakthrough enabled by artificial intelligence (AI) has been recognized with a Nobel prize. The 2024 chemistry Nobel was awarded to John Jumper and Demis Hassabis at Google DeepMind in London, for developing a game-changing AI tool for predicting protein structures called AlphaFold, and David Baker, at

En (très) résumé...

IA pour les sciences: le nouveau graal de la communauté scientifique

- environ 80 150 publications sur l'IA en sciences naturelles en 2025, soit +26 % en un an.
- Objectif: combiner les connaissances scientifiques et l'apprentissage profond
- Déjà beaucoup d'approches prometteuses (PINN et FNO ne sont que deux exemples)

Des succés réels

- Par ex., plusieurs modèles météo IA sont déployés opérationnellement (prévisions jusqu'à 60 jours en moins de 4 minutes sur un GPU)
- Mais **encore beaucoup de problèmes ouverts**: interprétabilité, généralisation (on y est pas encore), problème inverse (découvrir des lois de la physique à l'aide de l'IA)
- Énormement de potentiel pour faire progresser les sciences et l'ingénierie **mais est-ce que l'IA remplace l'expérimentation?**

Une ingrédient clé pour les *World Models* *?...

* les World models sont des IA capables de comprendre la dynamique du monde réel, y compris la physique et les propriétés spatiales